

ВСЕ СТОИТ НА МЕСТЕ

все fr стоит на месте: доли тем, геометрия векторов, покрытие словаря, устойчивость кластеров

мерить нечего?

PS этот ноутбук я оформлял самым последним, потому какие то детали могу упускать(
Импорты

```
import os, warnings; warnings.filterwarnings("ignore")
while not os.path.isdir("chats"): os.chdir("..")
import json, numpy as np, pandas as pd, seaborn as sns, joblib
sns.set_theme(style="whitegrid", palette="deep", rc={"figure.figsize": (8, 4.5)})
```

```
df = pd.read_csv("chats/physics/df.csv", parse_dates=["ts"])
yr_all = dict(zip(df["unit_id"], df["year"]))
meg_all = dict(zip(df["unit_id"], df["mega"]))
df = df[~df["is_bot"]].reset_index(drop=True)
cats = sorted(df["mega"].unique())
```

```
df.iloc[0]
```

```
ids = json.load(open("chats/physics/vec/ids_ctx.json"))
row = {u: i for i, u in enumerate(ids)}
B = np.load("chats/physics/vec/dense_ctx.f16.npy").astype(np.float32)
B /= np.linalg.norm(B, axis=1, keepdims=True) + 1e-9 #для устойчивости
len(B)
```


```
120127
```

ДОЛИ ТЕМ ПО ВРЕМЕНИ ПО ВРЕМЕНИ

Посчитаем как меняется доля тем (если считать это как количество сообщений в окне которые принадлежат теме k) от скользящего окна

```
df["кв"] = df["ts"].dt.to_period("Q").astype(str)
t = df.groupby(["кв", "mega"]).size().reset_index(name="n")


t["доля"] = t["n"] / t.groupby("кв")["n"].transform("sum")
sns.lineplot(data=t, x="кв", y="доля", hue="mega", marker="o")
```



все темы в меру своего среднего скачут достаточно сильно

но четкого тренда не прослеживается Посмотрим это в более удобной тепловой карте


```
M = t.pivot(index="mega", columns="кв", values="доля")
sns.heatmap(M.loc[cats])
```




сравним доли тем в 2024 и 2026

```
p24 = df[df["year"] == 2024]["mega"].value_counts(normalize=True)
p26 = df[df["year"] == 2026]["mega"].value_counts(normalize=True)

comp = pd.DataFrame({"2024": p24, "2026": p26})
sns.regplot(data=comp, x="2024", y="2026")
```



```
comp2 = comp.rename_axis("mega").reset_index().melt("mega", var_name="год",
    ↪ value_name="доля")
sns.barplot(data=comp2, y="mega", x="доля", hue="год")
```



#выглядит похоже очень

словарь тем не перестает быть актуальным!

в пайплайне центроиды построены на ОДНОМ 3-месячном окне, проверим работает ли этот словарь на ВСЕМ корпусе:

если нет на далеких по времени сообщениях то среднее расстояние до ближайшей темы (кластера) должно расти (темы "уезжают") - как скалярная норма в норм пространстве - сделаем агрег статистику

```
df.iloc[0]
```


```
m = joblib.load("chats/physics/topics/model.joblib")
m
```

```
{ 'pca': PCA(n_components=50, random_state=0, whiten=True),
  'km': KMeans(n_clusters=50, n_init=10, random_state=0),
```

```
'train_mean': array([ 0.00037027, -0.0033898 , -0.00143221, ..., -0.00234687,
                    -0.01448215, -0.0017053 ], dtype=float32),
'drop_first': False}
```

```
W = m["pca"].transform(B - m["train_mean"])
d1 = m["km"].transform(W).min(1)
df["d1"] = [d1[row[u]] for u in df["unit_id"]]
```

```
sns.lineplot(data=df, x="кв", y="d1")
```



```
#примерно константа на всех 3 годах
#тогда словарь с одного окна покрывает весь корпус, не перестает быть
↳ репрезентативным!!!!!!
```

само многообразие фиксировано

не только доли, но и форма облака векторов

сначала косинусы случайных пар по годам

посмотрим на распределения кос сходства случайных пар по разным годам

```
t = np.array([yr_all[u] for u in ids])
t
```

```
array([2023, 2023, 2023, ..., 2026, 2026, 2026])
```


```
def pair_cos(year):
    idx = np.where(t == year)[0]
    a = W[np.random.choice(idx, 5000)]
    b = W[np.random.choice(idx, 5000)]
    return (a * b).sum(1) / (np.linalg.norm(a, axis=1) * np.linalg.norm(b,
    ↳ axis=1))
```

```
res = pd.DataFrame({"cos": list(pair_cos(2023)) + list(pair_cos(2025)),
                    "год": ["2023"]*5000 + ["2025"]*5000})
res
```


	cos	год
0	0.118439	2023
1	0.106869	2023
2	-0.118134	2023
3	0.108094	2023
4	0.088279	2023
...	...	...
9995	0.094490	2025
9996	-0.074636	2025
9997	-0.138132	2025
9998	0.261785	2025
9999	0.222204	2025

[10000 rows x 2 columns]

```
sns.kdeplot(data=res, x="cos", hue="год", fill=True)
```



```
res = pd.DataFrame({"cos": list(pair_cos(2023)) + list(pair_cos(2024)) +
    ↳ list(pair_cos(2025)) + list(pair_cos(2026)),
    "год": ["2023"]*5000 + ["2024"]*5000 + ["2025"]*5000 +
    ↳ ["2026"]*5000})
sns.kdeplot(data=res, x="cos", hue="год", fill=True)
```



```
#практически не отличается распределение
#можно помахать руками что тут все статично
```

как центроиды двигаются???

```
g = np.array([meg_all[u] for u in ids])
g

array(['Разбор задач', 'Разбор задач', 'Разбор задач', ...,
      'Оффтоп/болтовня', 'Оффтоп/болтовня', 'Оффтоп/болтовня'],
      dtype='<U24')

years = [2023, 2024, 2025, 2026]

rows = []
for c in cats:
    v_all = B[g == c].mean(0)          # центроид темы за ВСЕ годы (эталон)
    v_all /= np.linalg.norm(v_all)
    for y in years:
        v = B[(t == y) & (g == c)].mean(0)
        v /= np.linalg.norm(v)
        rows.append({"тема": c, "год": y, "cos": v @ v_all})
rows = pd.DataFrame(rows)

rows
```

	тема	год	cos
0	others	2023	NaN
1	others	2024	NaN
2	others	2025	NaN
3	others	2026	NaN
4	Баллы и апелляции	2023	NaN
5	Баллы и апелляции	2024	NaN
6	Баллы и апелляции	2025	NaN
7	Баллы и апелляции	2026	NaN
8	Логистика и быт	2023	NaN
9	Логистика и быт	2024	NaN
10	Логистика и быт	2025	NaN
11	Логистика и быт	2026	NaN
12	Мета	2023	NaN
13	Мета	2024	NaN
14	Мета	2025	NaN
15	Мета	2026	NaN
16	Оффтоп/болтовня	2023	NaN
17	Оффтоп/болтовня	2024	NaN
18	Оффтоп/болтовня	2025	NaN
19	Оффтоп/болтовня	2026	NaN
20	Поступление и подготовка	2023	NaN
21	Поступление и подготовка	2024	NaN
22	Поступление и подготовка	2025	NaN
23	Поступление и подготовка	2026	NaN
24	Разбор задач	2023	NaN
25	Разбор задач	2024	NaN
26	Разбор задач	2025	NaN
27	Разбор задач	2026	NaN

```
array([ True,  True,  True, ...,  True,  True,  True])
```

```
# gemini сделал эти прекрасные графички {
```

```


import matplotlib.pyplot as plt
years = [2023, 2024, 2025, 2026]

def cen(c, y):
    v = B[(g == c) & (t == y)].mean(0)
    return v / np.linalg.norm(v)

fig, axes = plt.subplots(2, 4, figsize=(15, 7))
for c, ax in zip(cats, axes.flat):
    M = [[cen(c, y1) @ cen(c, y2) for y2 in years] for y1 in years]
    sns.heatmap(M, ax=ax, xticklabels=years, yticklabels=years,
                annot=True, fmt=".3f", vmin=0.98, vmax=1, cbar=False)
    ax.set_title(c)
axes.flat[-1].axis("off")
#}

(np.float64(0.0), np.float64(1.0), np.float64(0.0), np.float64(1.0))

```



#все ~0.98-0.99 - центры тем стоят на месте

ИТОГИ

все стоит:

1. доли тем не меняются (по годам сильно скореллированы)
 2. словарь тем с одного 3-мес окна одинаково покрывает все 3 года
 3. геометрия векторов не двигается: тот же конус, центры тем стоят
- то есть агрегированные статистики неподвижны - многообразия фиксированы

ТВН я очень расстроился когда увидел это и подумал что тут нечего делать